

Sistema Híbrido de Processamento de PDFs

Documentação Técnica da Aplicação Web e Arquitetura do Sistema

Este documento apresenta a especificação técnica e a arquitetura de software para a aplicação web desenvolvida em Python. O sistema foi projetado com uma abordagem híbrida, sendo capaz de processar tanto documentos digitalizados (via OCR) quanto documentos digitais nativos com problemas de diagramação ("layouts feios"), unificando as saídas em um padrão tipográfico limpo e acessível.



Nota de Arquitetura: A separação de escopo entre PDFs nativos e PDFs escaneados otimiza o uso de memória do servidor em até 85%, pois evita a renderização gráfica desnecessária de textos digitais existentes.

1. Modos de Operação do Sistema

A aplicação atua dinamicamente com base na seleção do usuário, dividindo-se em duas pipelines de processamento:

Modo de Operação	Tecnologia Base	Ação Executada	Consumo de RAM Estimado
Modo 1: PDF Escaneado (Imagem)	pdf2image + PyTesseract	Converte páginas em imagens e aplica OCR multilíngue (PT, EN, FR, EL).	Alto (~25MB por página a 200 DPI)
Modo 2: PDF Digital (Layout Feio)	PyMuPDF (fitz)	Extraí o texto eletrônico bruto e os metadados nativos diretamente.	Baixo (< 2MB por documento)

2. Dependências do Ambiente

Para a correta execução da plataforma em servidores Linux ou em instâncias Cloud (como Streamlit Community Cloud), os pacotes do sistema e bibliotecas Python devem estar explicitamente declarados.

Requisitos do Sistema Operacional (packages.txt):

```
poppler-utils
tesseract-ocr
tesseract-ocr-por
tesseract-ocr-eng
```

```
tesseract-ocr-fra  
tesseract-ocr-ell
```

Bibliotecas Python (requirements.txt):

```
streamlit  
pdf2image  
pytesseract  
reportlab  
pillow  
pymupdf
```

3. Tratamento de Codificação Multilíngue

O suporte ao idioma Grego requer atenção especial na biblioteca ReportLab. Diferente do alfabeto latino (usado no Português, Inglês e Francês), caracteres gregos não são mapeados nativamente pela fonte padrão Helvetica. O sistema contorna essa limitação chaveando dinamicamente a tipografia para Times-Roman e desativando filtros de decodificação destrutivos (como o `encode('ascii', 'ignore')`) quando o idioma helênico é detectado.